Predicción de la demanda en servicios de reparto mediante series temporales: volumen y distribución horaria de pedidos

MÁSTER EN DATA SCIENCE Y BUSINESS ANALYTICS

MÁSTER TELEPRESENCIAL - 2025

TFM elaborado por: David Licián Martínez

Tutor/a de TFM: Juan Manuel Moreno Lamparero

Contexto del problema

- La empresa lleva más de 10 años operando, pero su planificación semanal se basaba en la intuición.
- Los gerentes se enfrentan a picos de demanda impredecibles, pero necesitan saber con cuántos empleados contar en cada franja horaria.
- En restauración, saber cuántos pedidos llegarán en cada hora puede marcar la diferencia entre eficiencia y caos.

Por qué importa predecir la demanda

Una predicción **imprecisa** de la demanda

- Conlleva excedente/falta de empleados
- Incurre en pérdidas
- Disminuye ingresos
- Provoca retrasos

Una predicción **precisa** de la demanda

- Optimiza recursos
- Minimiza pérdidas
- Genera satisfacción en el cliente
- Evita retrasos

La predicción no es un lujo, es una **necesidad real** para tomar decisiones inteligentes.

En qué consiste el proyecto

No se trata solo de predecir el volumen global, sino su **distribución horaria semanal**, que es la que determina la planificación de personal.

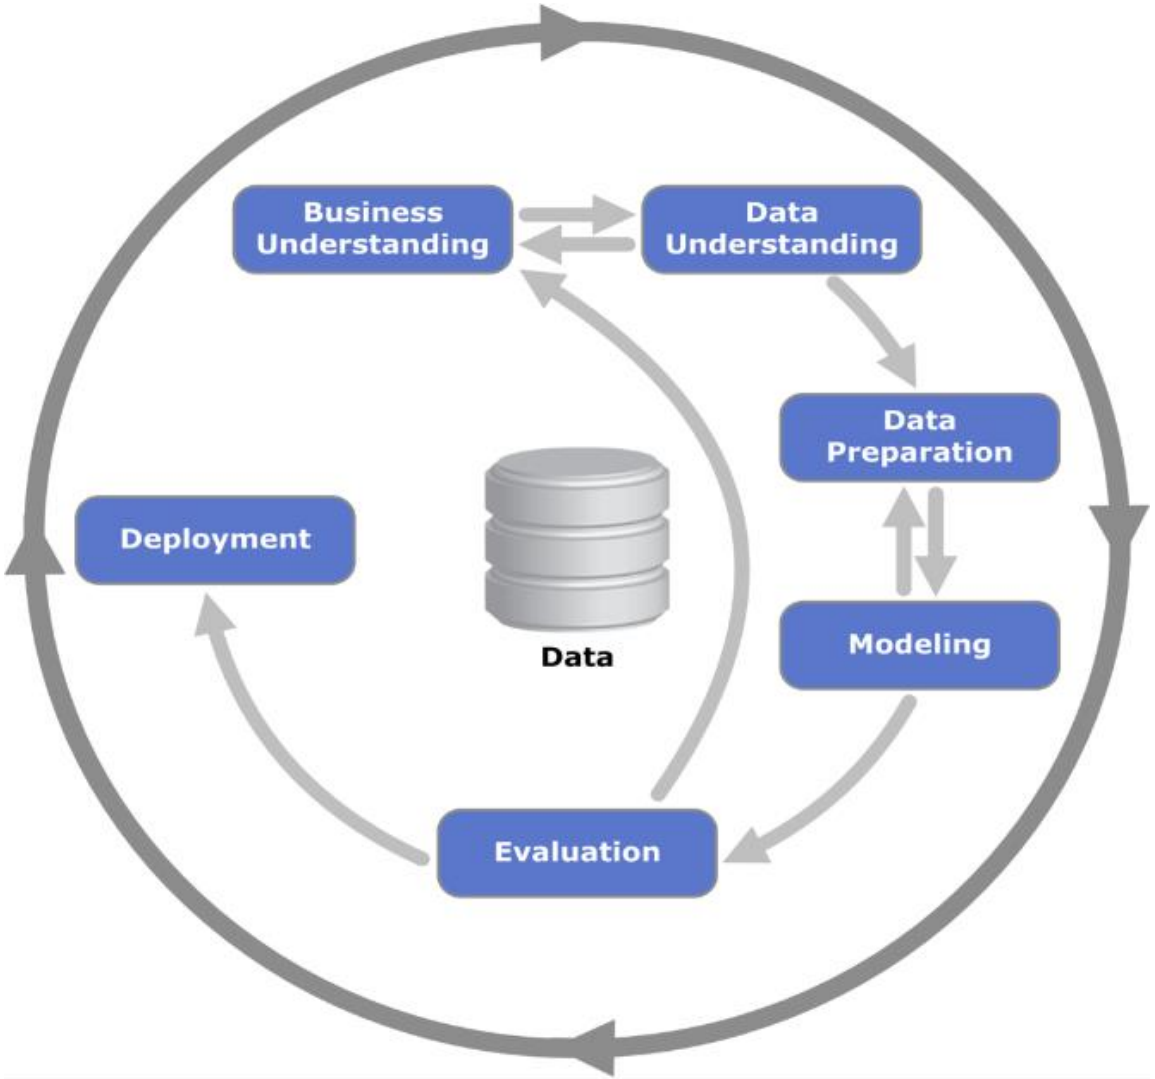

Fuente: imagen obtenida de Internet

Objetivos generales

Objetivos empresariales: Ofrecer un servicio de calidad con el mínimo coste de personal y el máximo retorno de beneficio.

Objetivo del científico de datos: Desarrollar un modelo capaz de predecir la demanda semanal por tramos de 30 minutos, con al menos una semana de antelación.

Beneficios esperados: Incrementar la competitividad del negocio estableciéndose como una marca reputada con alta confiabilidad.

Objetivos específicos

- Construir un *pipeline* de extracción y limpieza de datos.
- Integrar fuentes externas (clima, fútbol, festivos, euríbor).
- Aplicar y comparar varios modelos (clásicos, ML, DL, híbrido).

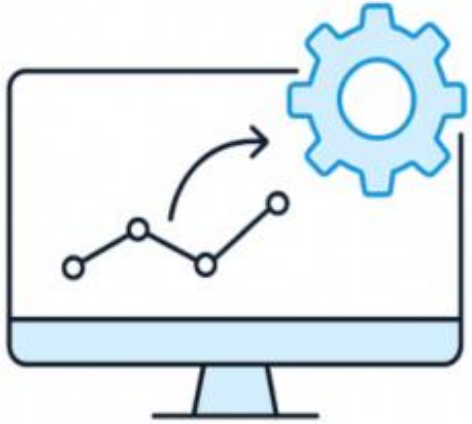

Fuente: imagen elaborada con ChatGPT

El proyecto cubre todo el ciclo de vida del dato: extracción, limpieza, enriquecimiento, modelado y validación. Además, sienta las bases para un futuro despliegue.

Fuentes de datos

Nuestro modelo integra tanto información interna como factores externos que afectan a la demanda:

- Registros de pedidos con 511 días de datos en intervalos de 30 minutos.
- Datos meteorológicos a través de la API de SiAR del MAPA.
- El calendario de festivos obtenidos con *web scraping* de Calendarios Ideal.
- La tasa del euríbor a 12 meses a través de la API del Banco de España.
- Los eventos futbolísticos a través de la API de LaLiga.

Fuente: imagen obtenida de Internet

Datos de pedidos

Primero separamos todos los pedidos en dos tipos:

- Para llevar a **domicilio**
- Para **recoger** en el local.

Después, descubrimos que la mayoría de los tramos tienen baja demanda, pero con mucha volatilidad.

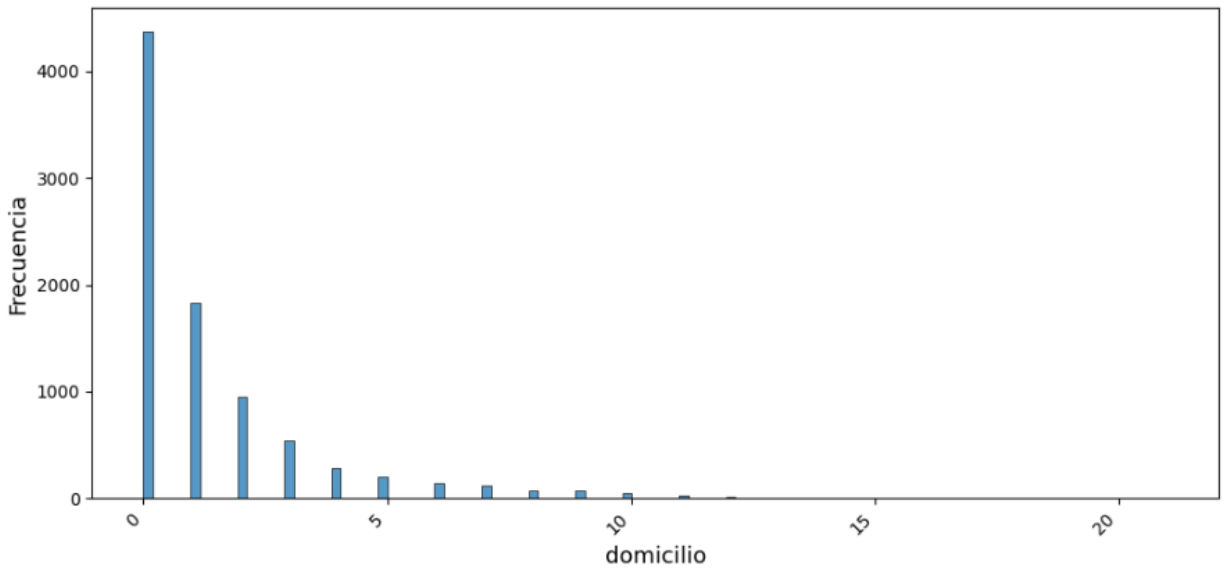

Fuente: imagen obtenida del *notebook*

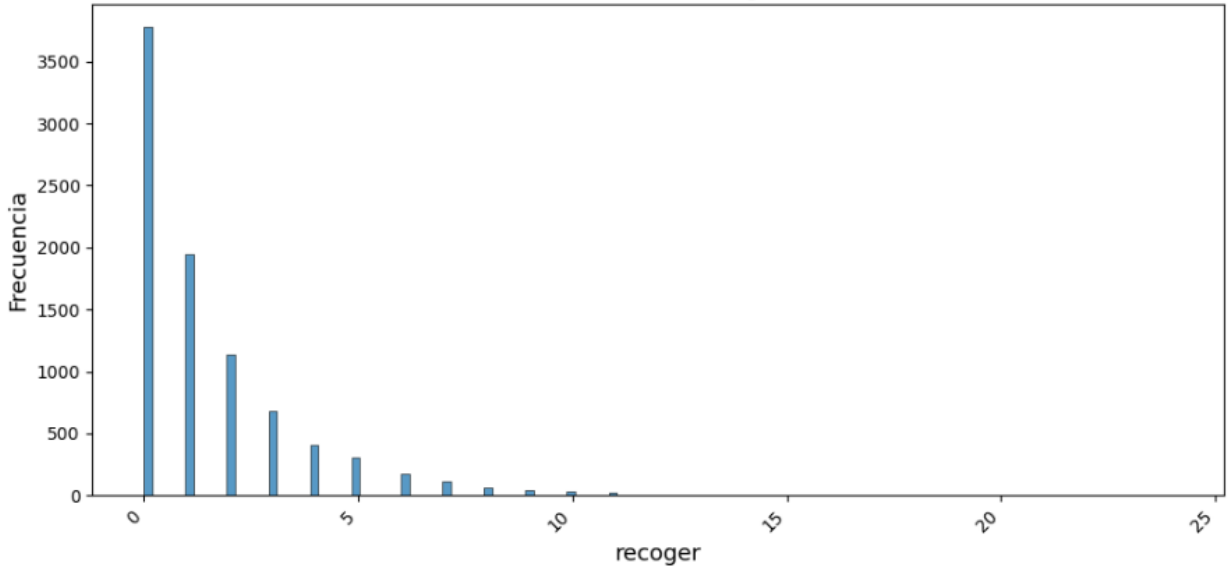

Fuente: imagen obtenida del *notebook*

Factores externos

Además, ciertos factores externos son muy relevantes:

- La presencia de **partidos** de fútbol modifica la distribución horaria de pedidos: antes, durante y después del inicio.
- Los **festivos** generan un impacto positivo en las ventas agregadas.

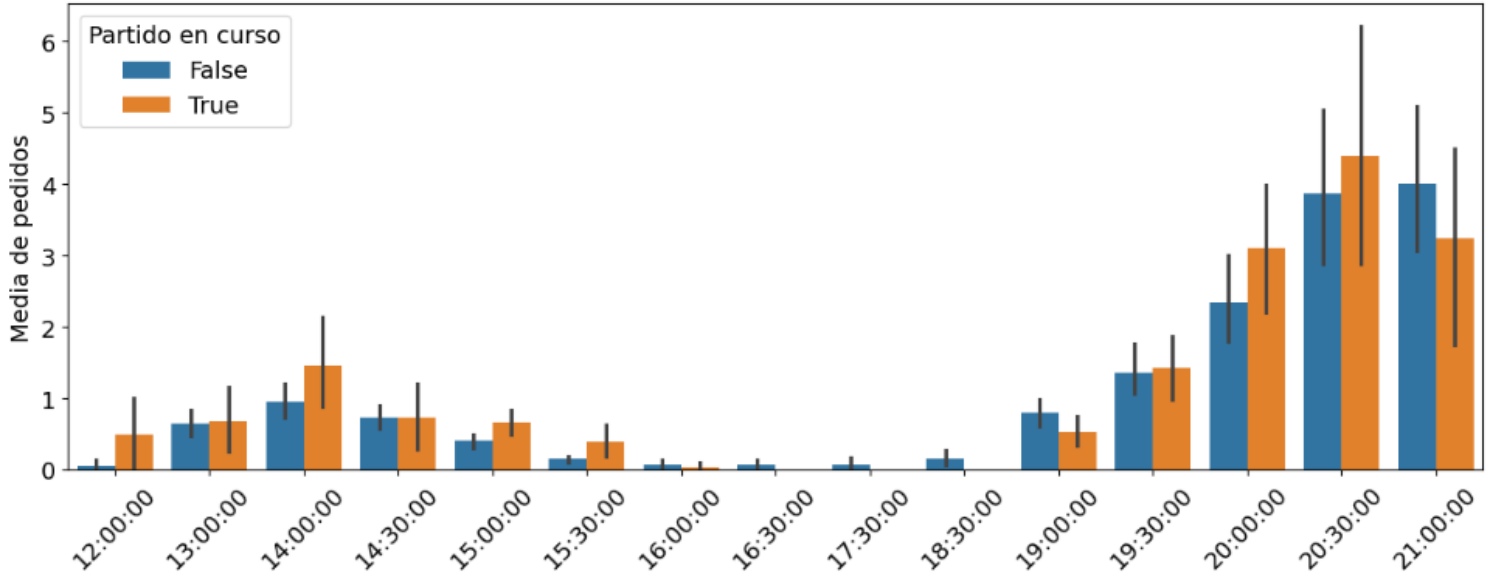

Fuente: imagen obtenida del *notebook*

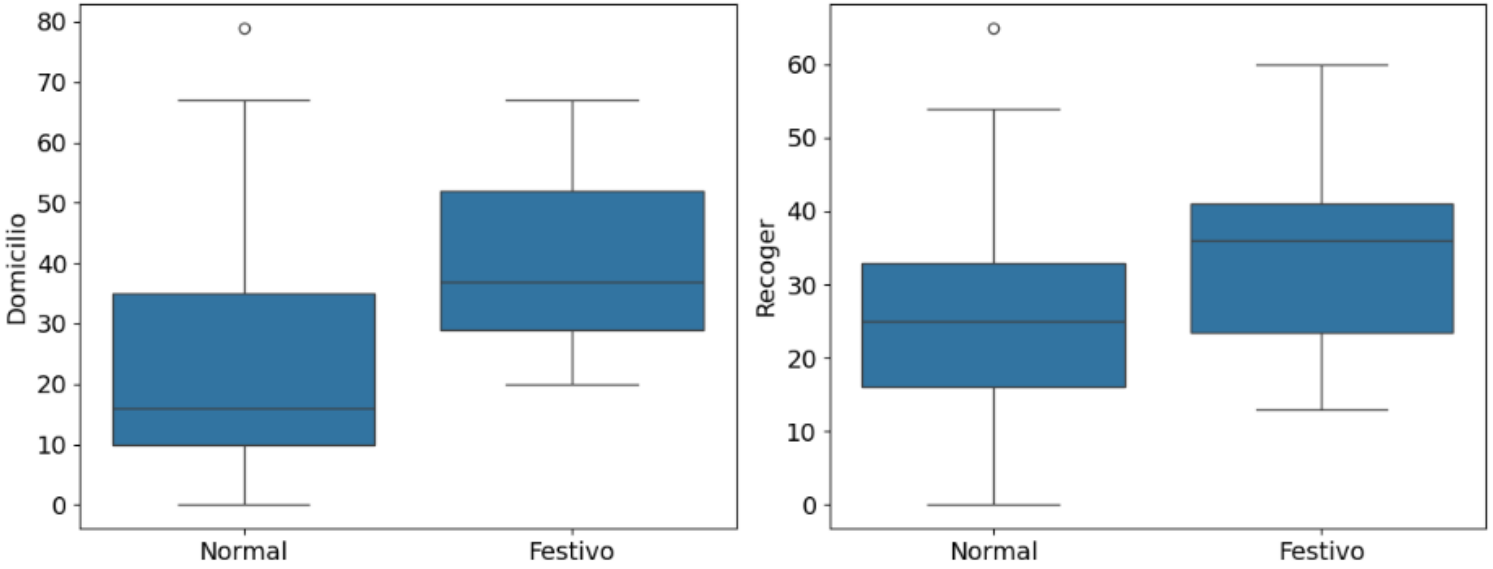

Fuente: imagen obtenida del *notebook*

Factores externos

Los eventos climáticos aleatorios, como la lluvia, no afectan a la demanda agregada.

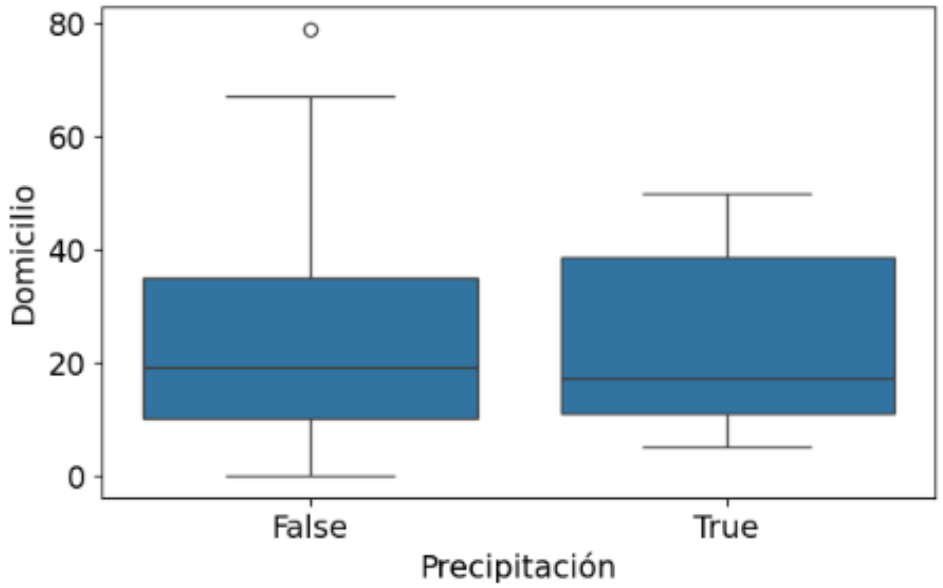

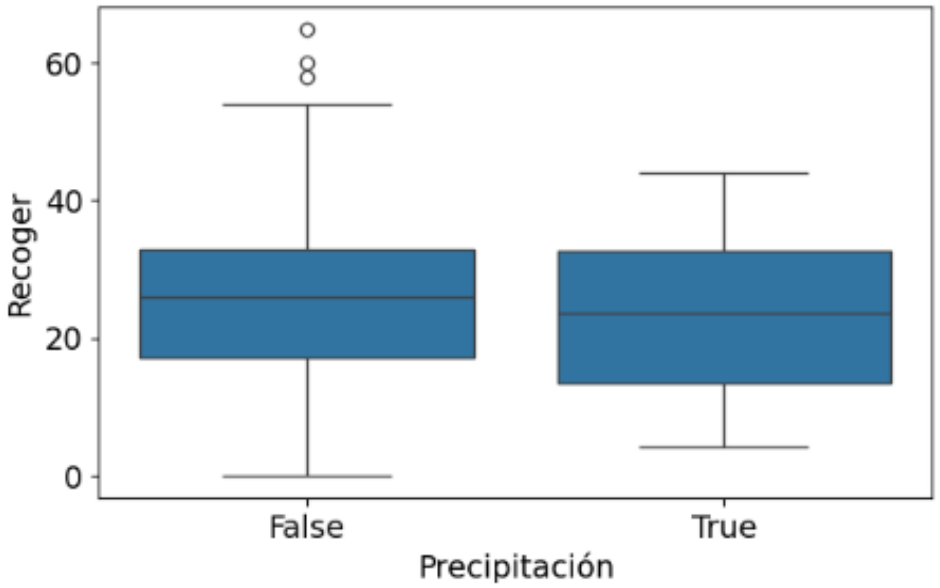

Fuente: imagen obtenida del *notebook*

Factores externos

El euríbor a 12 meses tampoco es una buena métrica a tener en cuenta para la demanda.

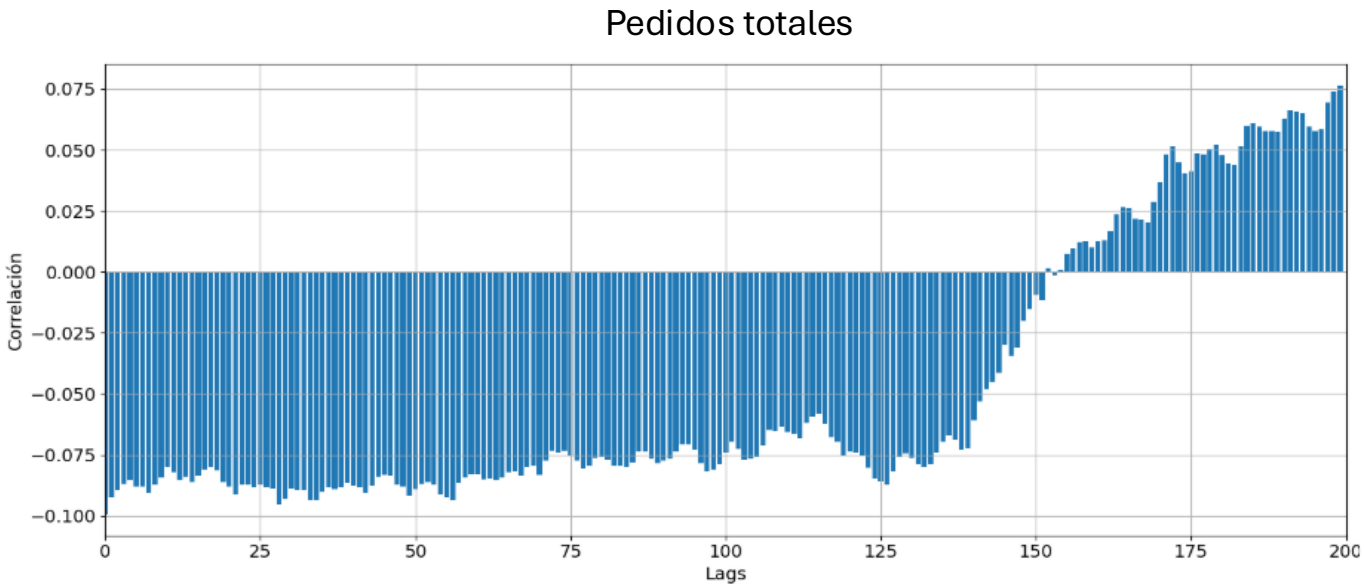

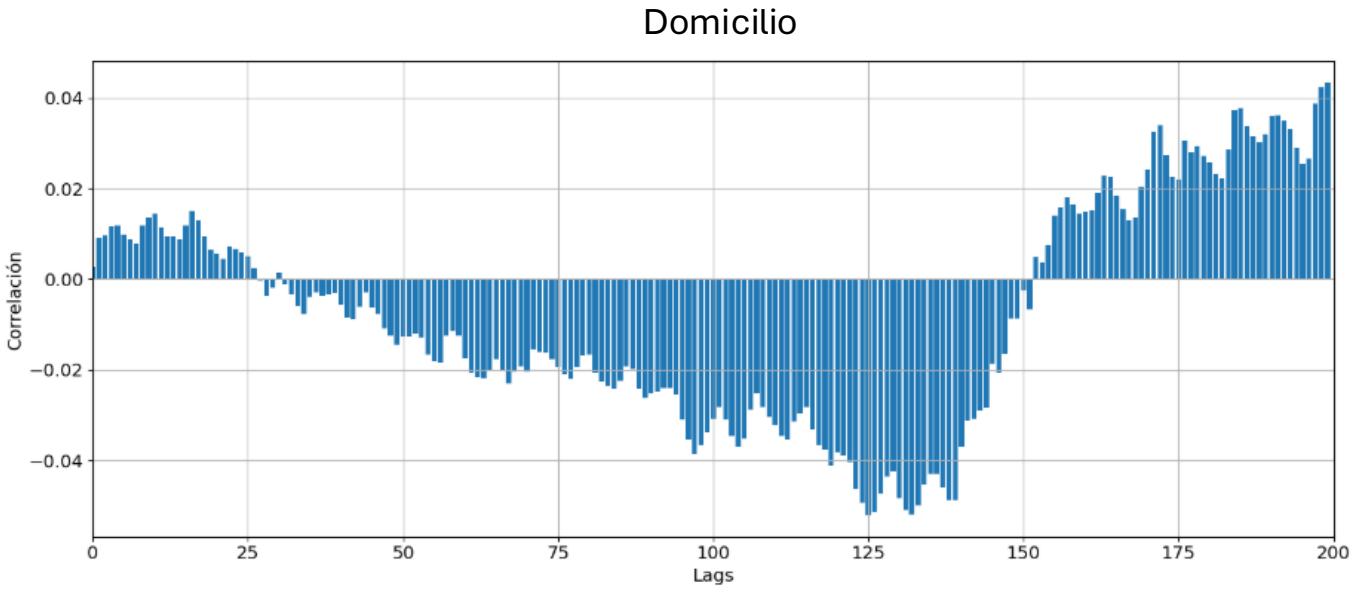

Fuente: imágenes obtenidas del *notebook*

Factores externos

Las **estaciones** del año **sí afectan** al patrón de consumo.

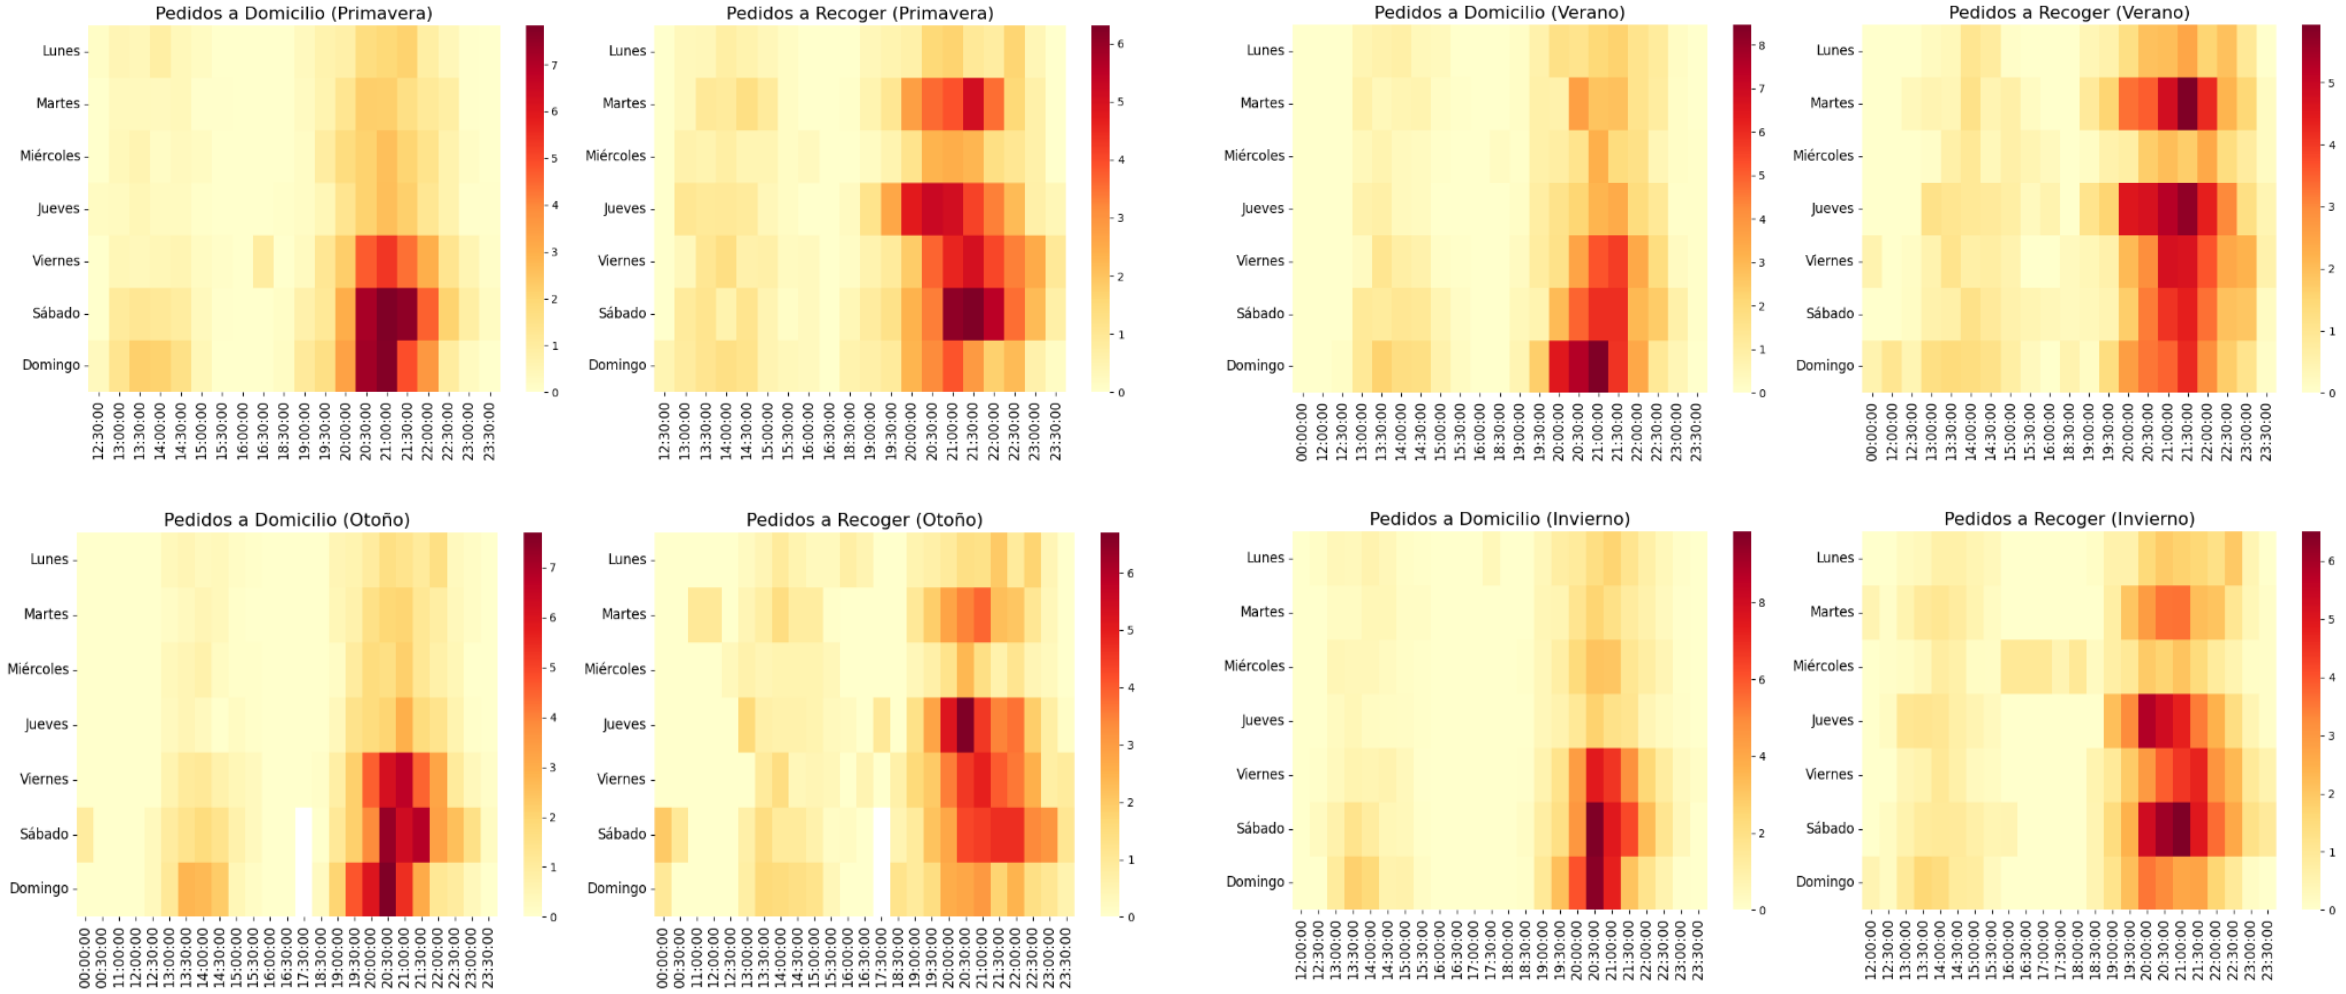

Fuente: imágenes obtenidas del *notebook*

Autocorrelaciones

La demanda presenta patrones claros:

- Los pedidos tienen una marcada **estacionalidad semanal**, y en menor medida una diaria.
- La demanda de pedidos a recoger y a domicilio suele variar de forma conjunta, creciendo o disminuyendo a la vez.
- Los martes y los jueves prima la demanda a recoger sobre la de domicilio por las ofertas especiales del negocio.

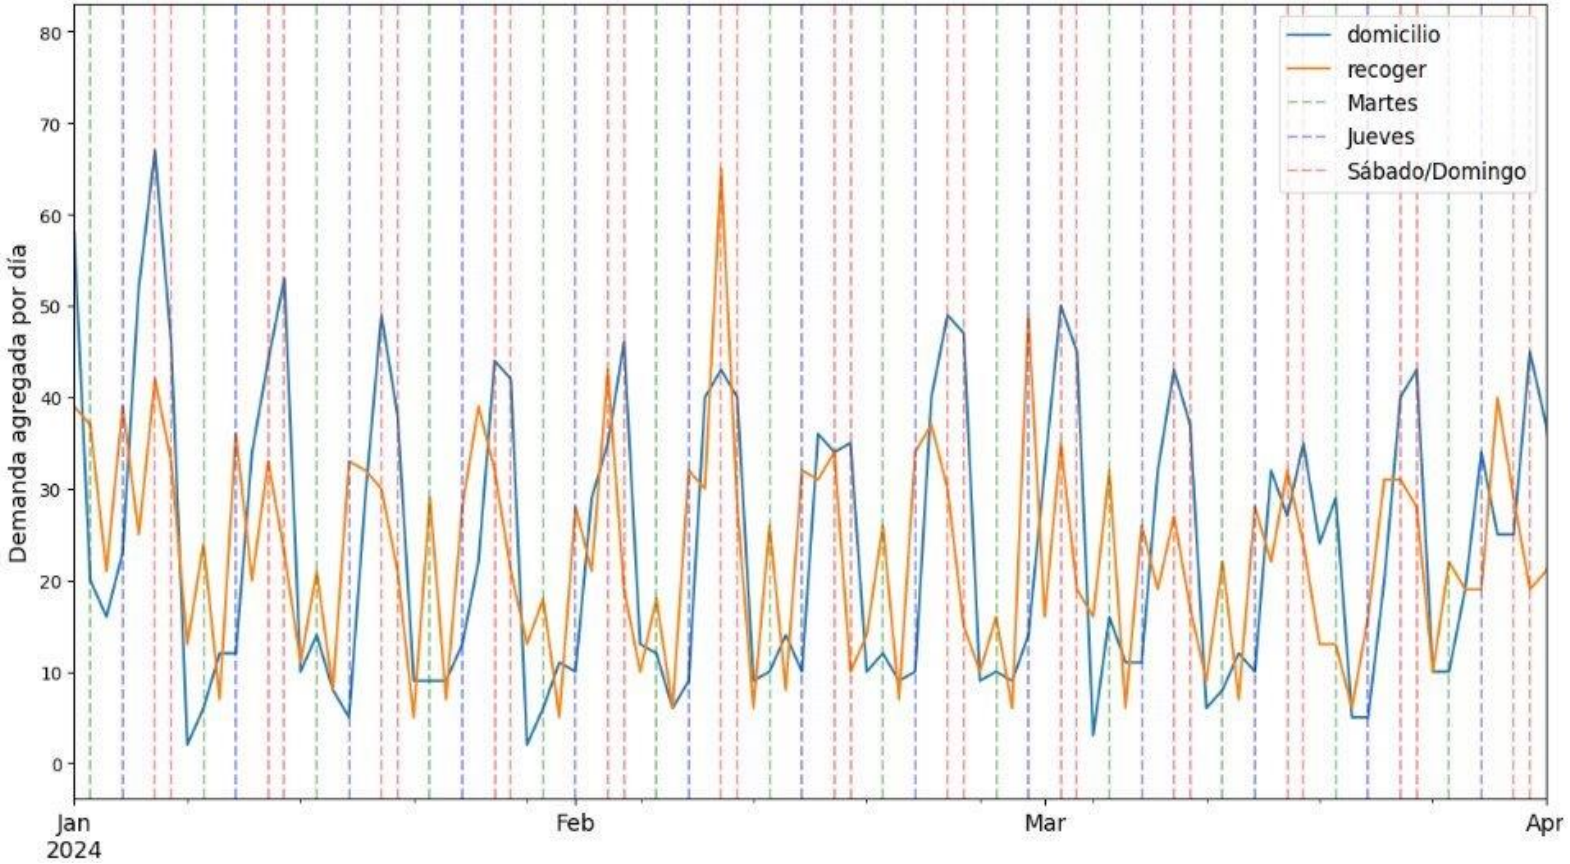

Fuente: imagen obtenida del *notebook*

Tipos de modelos evaluados

El objetivo era buscar el equilibrio entre interpretabilidad y precisión:

- Clásicos: SARIMAX, Prophet.
- *Machine learning*: LightGBM, Random Forest, XGBoost.
- *Deep learning*: LSTM, GRU.
- Híbrido: Media móvil estacional + LightGBM

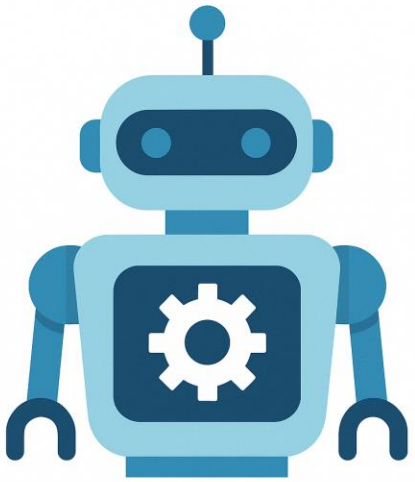

Fuente: imagen elaborada con ChatGPT

Cada enfoque tiene sus ventajas: los clásicos captan la estacionalidad y tendencia; los modernos, patrones complejos no lineales

Modelos clásicos

SARIMAX y Prophet:

- Capturan relaciones lineales y estacionales.
- Prophet es robusto ante valores atípicos y múltiples estacionalidades.
- Son modelos interpretables, pero con alcance limitado ante relaciones complejas.

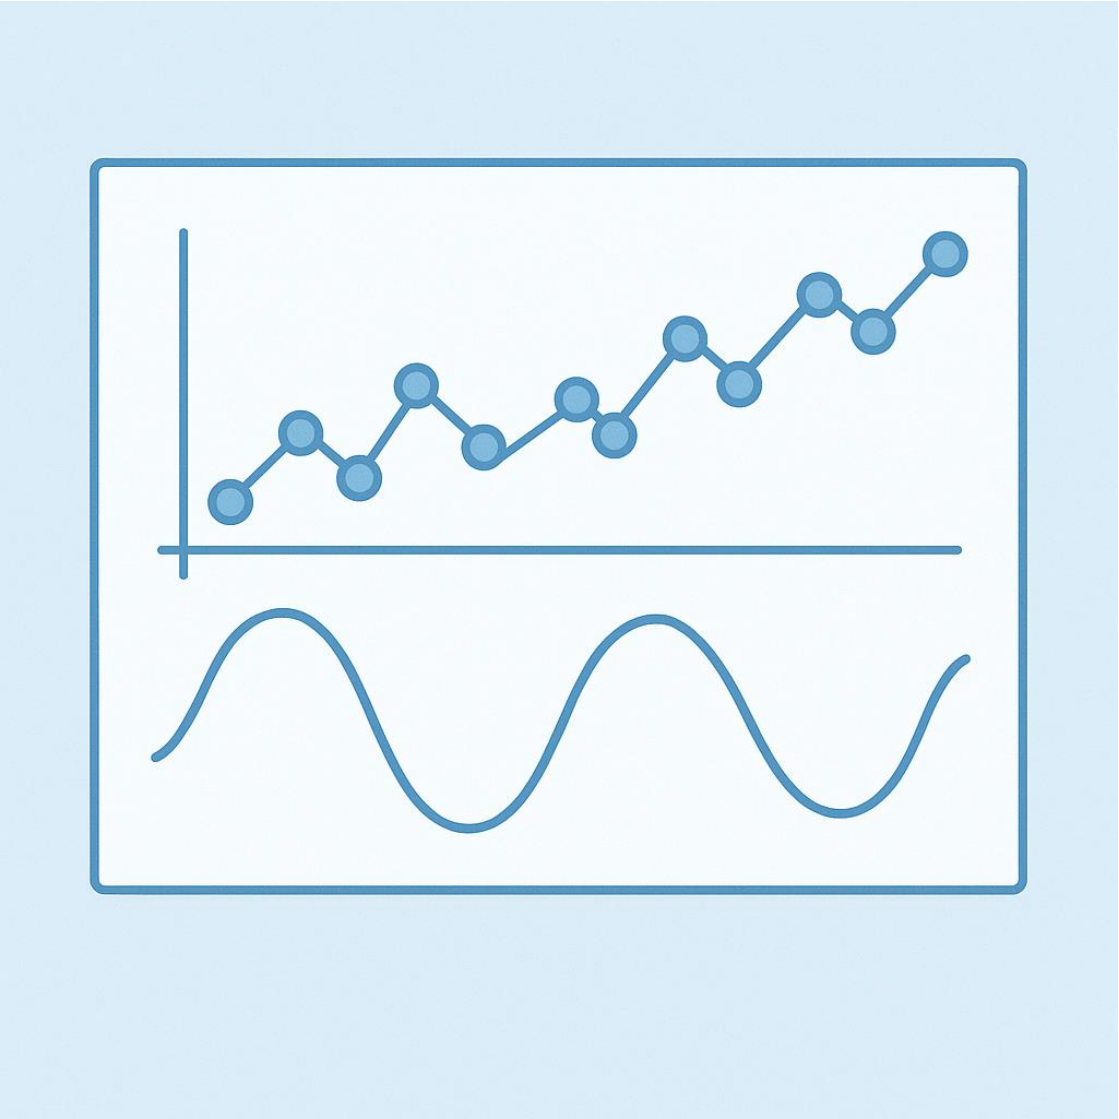

Fuente: imagen elaborada con ChatGPT

Modelos de *machine learning*

LightGBM, Random Forest y XGBoost:

- Son modelos basados en árboles que aprenden relaciones no lineales.
- Son resistentes a valores atípicos y eficientes con gran cantidad de variables.
- Requieren variables de rezago y exógenas para introducir la noción de tiempo.

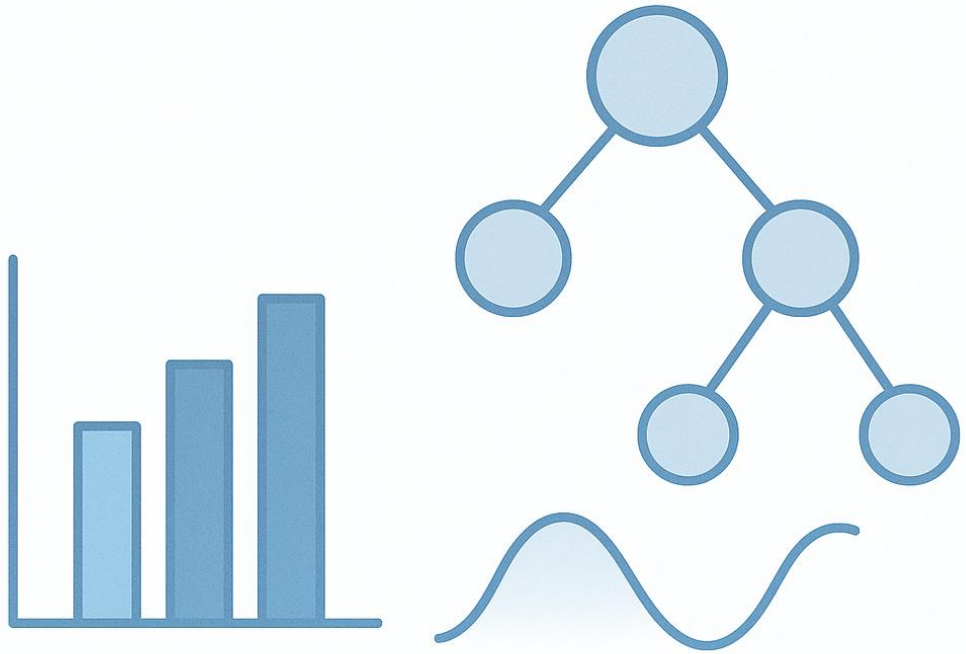

Fuente: imagen elaborada con ChatGPT

Modelos de *deep learning*

LSTM y GRU:

- Son modelos basados en redes neuronales recurrentes.
- Aprenden de secuencias temporales, pudiendo recordar patrones de largo plazo.
- Requieren más datos y potencia computacional.

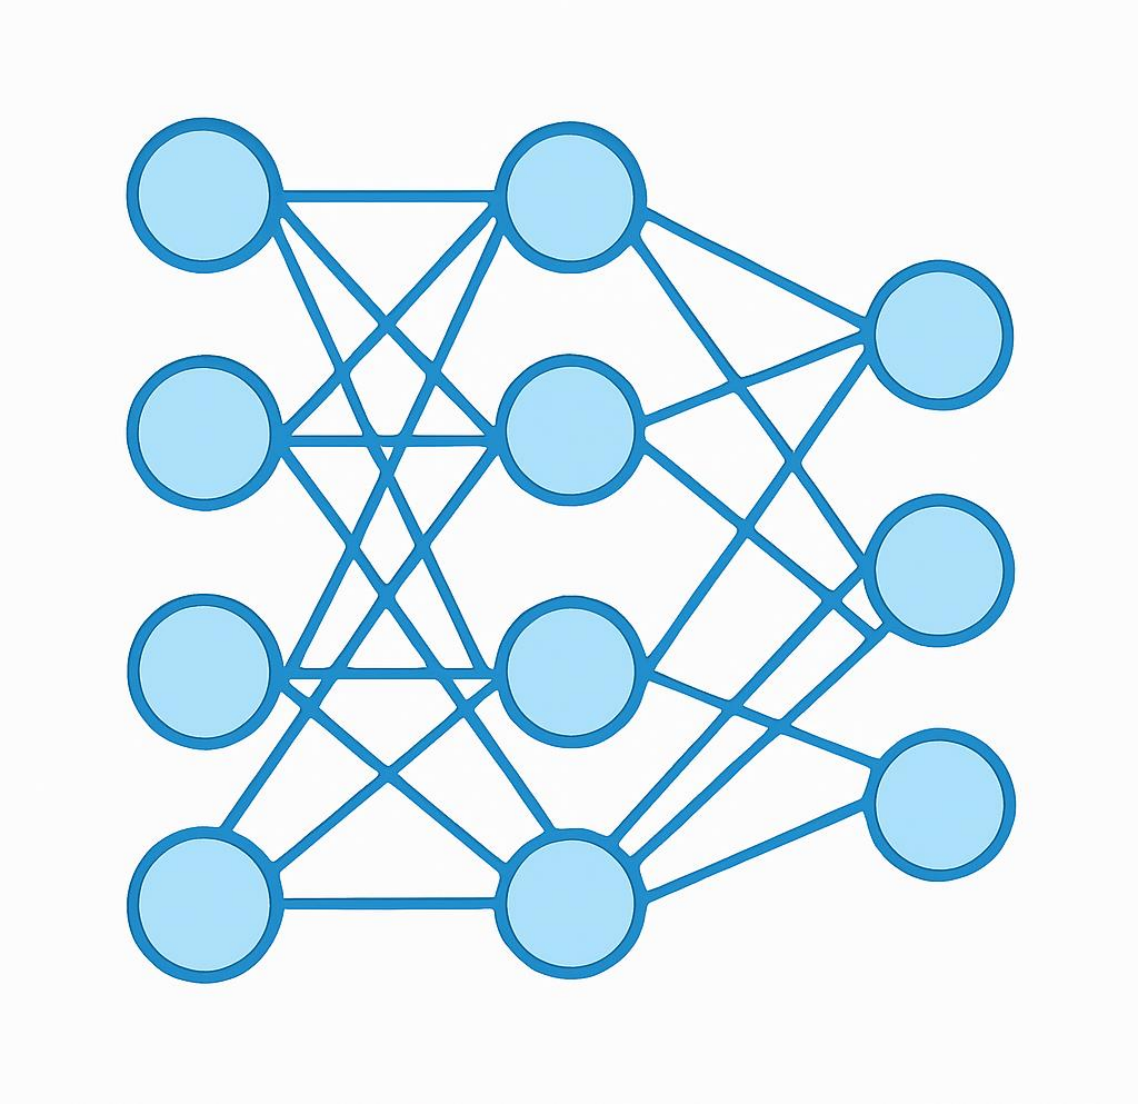

Fuente: imagen elaborada con ChatGPT

Modelo híbrido

- Es la combinación de un modelo de media móvil estacional con LightGBM.
- La componente de media móvil captura la estacionalidad intrínseca, mientras que LightGBM predice la componente irregular no explicada.
- Este enfoque combina lo mejor de ambos mundos, obteniendo el **mejor desempeño** y con muy **bajo coste computacional**.

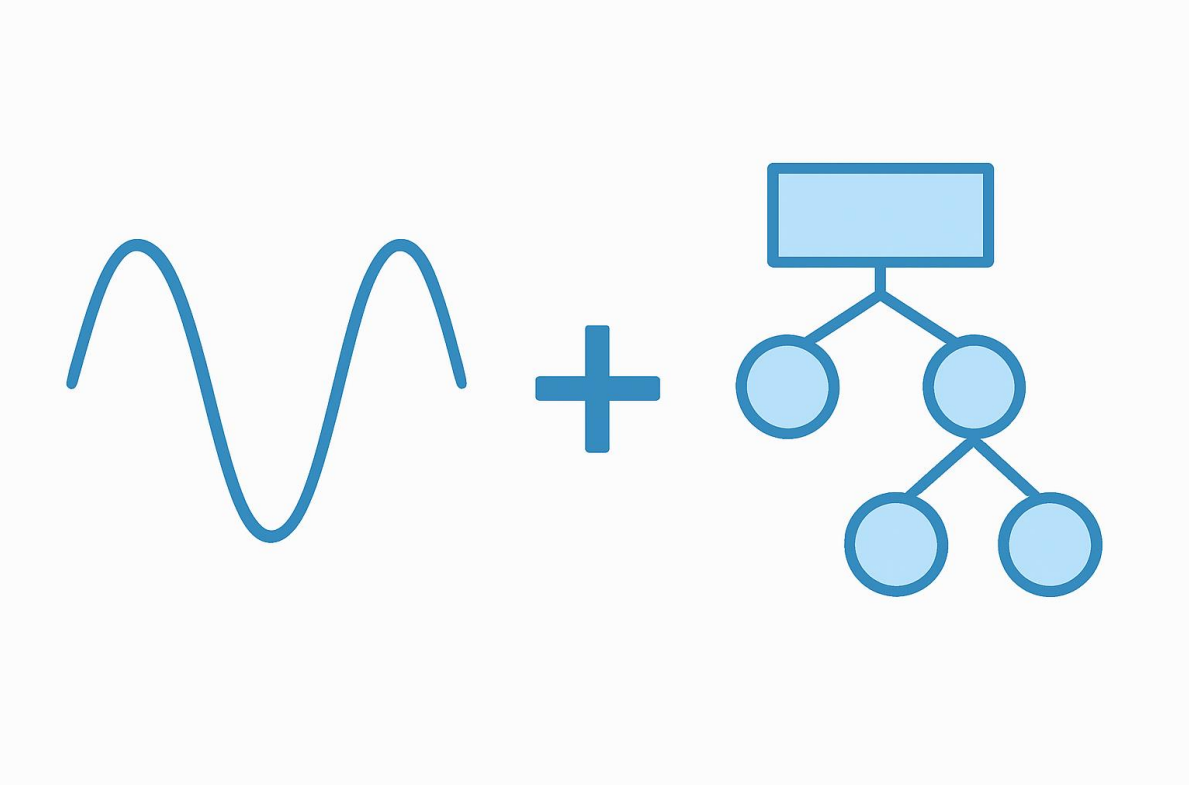

Fuente: imagen elaborada con ChatGPT

Evaluación de los modelos

- Se validó con dos tipos de ventanas temporales: fijas y crecientes.
- La métrica MAPE ayuda a medir la estabilidad del modelo.
- La métrica MAE cuantifica el error.

En promedio, en media hora el modelo se equivoca:

- Menos de 1 pedido para domicilio.
- Menos de 1 pedido y medio en pedidos totales.

Ventanas fijas

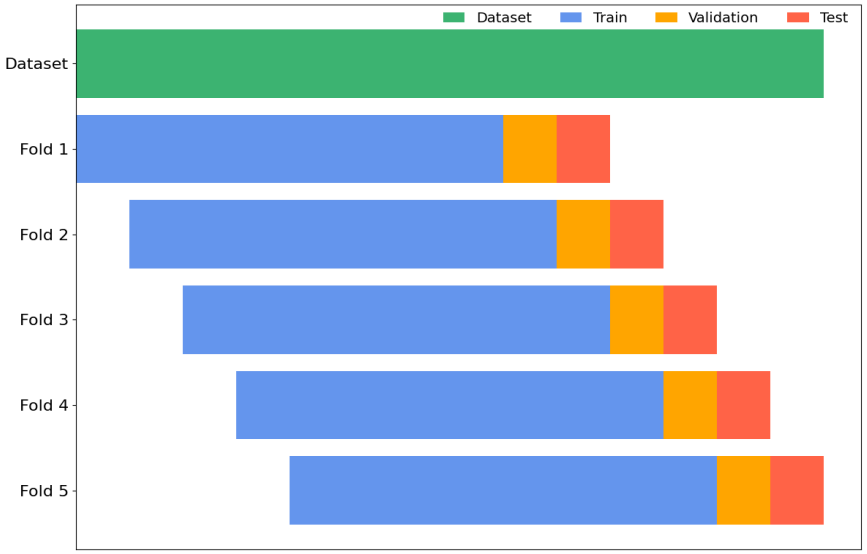

Fuente: imagen obtenida del *notebook*

Ventanas crecientes

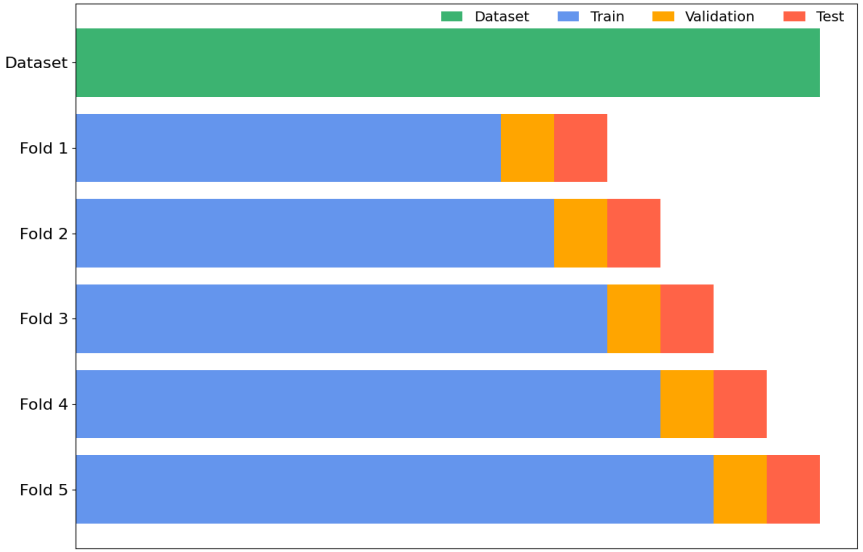

Fuente: imagen obtenida del *notebook*

Ejemplo visual de predicción

- El modelo predice con gran precisión las horas con baja demanda.
- Los periodos con alta demanda siguen siendo difíciles de capturar.

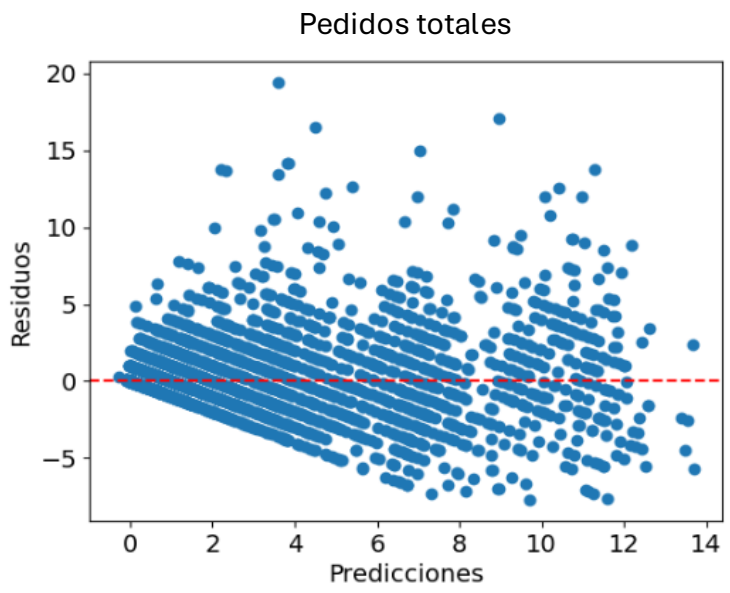

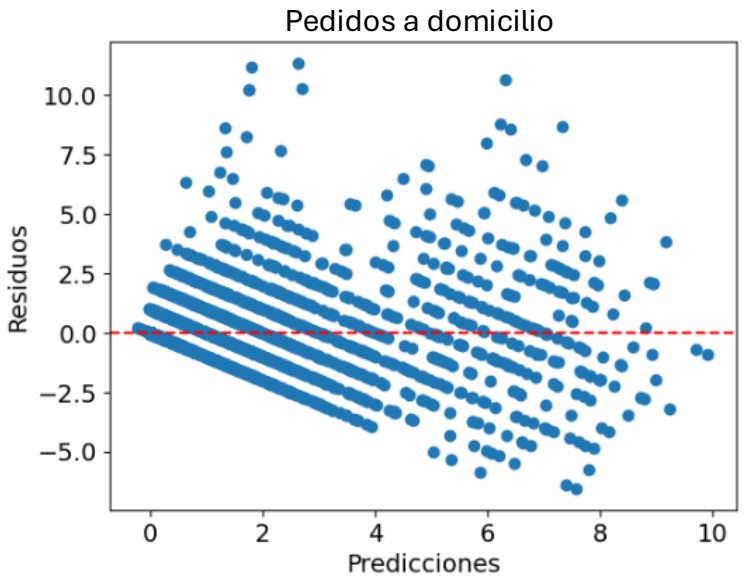

Fuente: imágenes obtenidas del *notebook*

Conclusiones principales

- El **modelo híbrido** logra el mejor equilibrio entre precisión y estabilidad.
- El modelo híbrido es el que mejor captura la estacionalidad semanal y los patrones de consumo.
- Se demuestra que un enfoque combinado puede superar tanto a modelos clásicos como a redes neuronales puras.

Beneficios empresariales

Al abandonar la intuición y confiar en los datos:

- Se optimizan los recursos humanos y materiales.
- Podemos reducir costes y mejorar la planificación.
- Elaborar horarios se vuelve más sencillo y directo.

Ya no hay que adivinar si hará falta más personal el viernes:

El modelo te lo dice

Fuente: imagen elaborada con ChatGPT

Limitaciones

- El proyecto solo cubre 1 año y medio de datos.
- Tampoco tenemos en cuenta la competencia.
- Algunos picos de demanda siguen siendo impredecibles.

Los resultados son prometedores, pero podrían mejorar con más histórico o fuentes adicionales.

Fuente: imagen elaborada con ChatGPT

Futuras líneas de trabajo

El siguiente paso es:

- Desplegar el modelo en la nube con Google Colab.
- Conectarlo a la base de datos del negocio.
- Hacer que genere las predicciones automáticamente los lunes.

Fuente: imagen obtenida de Internet

Fuente: imagen elaborada con ChatGPT

Queremos que el modelo trabaje solo

Impacto y aprendizaje personal

Como científico de datos, este proyecto me ha nutrido a nivel personal:

- Otorgándome experiencia completa en el ciclo de vida del dato.
- Permitiéndome encontrar una aplicación real de la ciencia de datos a un problema empresarial.
- Aprendiendo que los datos son más que números. Son necesidades. Son decisiones. Son personas.

Conclusión final

- Este trabajo demuestra que la analítica avanzada puede transformar decisiones cotidianas, bajo las preguntas adecuadas.
- Al final, convertir los datos en decisiones útiles es el propósito de la Ciencia de Datos.

Gracias por su atención